

TECNICATURA EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



Entregable: Actividades de Procesamiento de Datos -

Semana 04

Alumno: Nestor Martin Ozuna.

Profesor: Nicolas Caballero.

Materia: Procesamiento de Datos.

Actividad 1

Apache Kafka es ampliamente utilizado por organizaciones de la lista Fortune 500 para proporcionar experiencias basadas en datos en tiempo real. Entre los casos destacados se incluyen:

- Empresas como Target, Microsoft, AirBnB y Netflix confían en Kafka para sus operaciones basadas en datos.
- Empresas como Yelp y Pinterest utilizan específicamente Kafka en sus pipelines como gestor de colas.

Actividad 2

Basado en los contenidos de la clase que definen estas arquitecturas, el video analiza la comparativa entre la Arquitectura Lambda y la Arquitectura Kappa:

- **Arquitectura Lambda:** Introducida por Nathan Marz, se caracteriza por utilizar distintas capas para el procesamiento (Batch Layer y Speed Layer). Es una arquitectura versátil y robusta, capaz de gestionar grandes volúmenes de datos históricos y procesamientos en tiempo real simultáneamente, lo cual la hace ideal para casos donde los resultados de batch y streaming pueden ser distintos, como en modelos de Machine Learning.
- **Arquitectura Kappa:** Introducida por Jay Kreps como una evolución que simplifica la anterior, elimina la capa batch y centraliza todo el procesamiento en una única capa de tiempo real (Real-time Layer) [: 178, 184]. Su filosofía se basa en que "todo es un stream" y que las operaciones batch son solo un subconjunto de las de streaming. Es la opción más acertada cuando el procesamiento necesario en las capas batch y streaming es el mismo.

Actividad 3

En el ecosistema de procesamiento de datos, la elección de una base de datos depende significativamente del caso de uso específico, el tipo de información que se desea almacenar y la naturaleza de las consultas que el sistema realizará. Debido a que los sistemas de almacenamiento llevan años existiendo, existe una gran variedad de soluciones disponibles.

La arquitectura modular de estos sistemas permite que se utilicen diferentes tecnologías para cada módulo, lo que significa que se podría emplear una base de datos específica para ciertos casos de uso y otra distinta para otros dentro del mismo sistema. Por lo tanto, no existe un motor único, sino que la adaptación depende de si la arquitectura elegida (Lambda o Kappa) prioriza la baja latencia, el histórico de datos o la complejidad de las consultas.

TECNICATURA EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



Actividad 4

1. **¿Cuál de los siguientes casos se ajusta mejor a una arquitectura Lambda?**
Respuesta: **C) Plataforma de recomendaciones de películas con datos históricos y eventos actuales.** Justificación: Lambda permite combinar una capa batch (datos históricos/entrenamiento) con una capa streaming (valoraciones en tiempo real).
2. **¿Qué componente de la arquitectura Lambda es responsable de entrenar modelos con grandes volúmenes de datos históricos?**
Respuesta: **C) Batch Layer.** Justificación: La capa batch gestiona la información en crudo y realiza el tratamiento de los datos existentes.
3. **¿Cuál de las siguientes tecnologías se asocia comúnmente con una arquitectura Kappa?**
Respuesta: **C) Kafka Streams.** Justificación: Kappa se basa en una capa de procesamiento en tiempo real (streaming), y las API de Kafka, como Streams API, permiten procesamiento continuo y sofisticado.
4. **En una app como Uber, que requiere reflejar la ubicación de autos en tiempo real, ¿qué arquitectura se recomienda y por qué?**
Respuesta: **B) Kappa, porque todo el flujo de datos es continuo y en tiempo real.** Justificación: Es un sistema similar al ejemplo de geolocalización de antena móvil mencionado, donde el evento debe procesarse en streaming para visualizar la posición.
5. **¿Cuál es la ventaja principal de la arquitectura Kappa sobre la Lambda?**
Respuesta: **B) Disminuye la duplicación de lógica de procesamiento.** Justificación: Al mantener un solo flujo, el código, el mantenimiento y la actualización se reducen considerablemente frente a la duplicación en Lambda.

Preguntas de Verdadero o Falso

- **6. En la arquitectura Lambda, los datos se envían exclusivamente a la capa de procesamiento batch.**
Respuesta: **Falso.** Los datos se envían tanto a la capa batch como a la capa streaming (Speed Layer).
- **7. La arquitectura Kappa no puede manejar algoritmos que requieran análisis sobre grandes volúmenes históricos de datos.**
Respuesta: **Falso.** El procesamiento batch es considerado un subconjunto del procesamiento en streaming, por lo que Kappa puede gestionar estos datos.
- **8. La arquitectura Lambda es ideal para escenarios donde los modelos de Machine Learning necesitan ser re-entrenados con datos históricos.**
Respuesta: **Verdadero.** La capa batch es adecuada para este tipo de procesamiento pesado y entrenamiento de modelos.
- **9. En aplicaciones como Waze, la arquitectura Lambda es preferible debido a su bajo tiempo de respuesta.**
Respuesta: **Falso.** Aplicaciones de tiempo real crítico suelen beneficiarse más de un flujo continuo y simplificado como Kappa, similar al ejemplo de geolocalización.
- **10. Apache Kafka puede ser usado como gestor de colas tanto en Lambda como en Kappa.**
Respuesta: **Verdadero.** Kafka es la tecnología estándar y más utilizada como gestor de colas en ambos tipos de arquitectura.