

PROCESAMIENTO DE DATOS

2º 1º Cuatrimestre



1. Clase 1

Clase N° 1: Introducción a datos e información y su conceptualización dentro del Big data

Contenido:

En la clase de hoy trabajaremos los siguientes temas:

- Conceptos introductorios sobre datos e información y su conceptualización dentro del Big data, es decir el manejo de grandes volúmenes de información.
- Características de los grandes volúmenes de datos y su diferencia con otros conceptos relacionados a la Ciencia de Datos.
- Tecnologías aplicadas y las estrategias que siguen las organizaciones para realizar una inteligencia del negocio que ayude a la toma de decisiones.

1. Presentación

Hola y bienvenidos al curso de Procesamiento de datos.

En esta primera semana vamos a trabajar con los conceptos introductorios sobre datos e información y su conceptualización dentro del Big data, es decir el manejo de grandes volúmenes de información.

También estudiaremos las características de los grandes volúmenes de datos y su diferencia con otros conceptos relacionados a la Ciencia de Datos. Introduciremos algunas tecnologías aplicadas y las estrategias que siguen las organizaciones para realizar una inteligencia del negocio que ayude a la toma de decisiones.

2. Desarrollo y actividades

Datos vs información

A pesar de que generalmente, los términos de datos e información se usan para describir lo mismo, para el profesional en tecnologías de información estos términos significan diferentes cosas.

Datos es un término que se refiere a hechos, eventos, transacciones, etc., que han sido registrados. Es la entrada sin procesar de la cual se produce la información.

Ejemplos de datos: un número (24), una palabra (Luis).

Información se refiere a los datos que han sido procesados y comunicados de tal manera que pueden ser entendidos e interpretados por el receptor.

Ejemplos de información: Luis tiene 24 años.


Actividad 1: ¿qué otros tipos de datos además numéricos existen? plantear ejemplos de distintos tipos de datos y luego transformarlos en información que represente algo. Usar alguna herramienta de I.A para generar ejemplos.

Ahora que ya sabemos cuál es la diferencia entre ambos conceptos vamos a introducir un nuevo concepto: Big data.

Big Data es un campo dedicado a tareas de análisis, procesamiento y almacenamiento de grandes conjuntos de datos que se originan desde diferentes fuentes. Generalmente se utilizan las soluciones de Big Data cuando las técnicas tradicionales son insuficientes para estas tareas.

A pesar de que Big Data puede definirse como una disciplina relativamente nueva, la realidad es que se basa en muchos principios y paradigmas conocidos hace muchos años. Existen gran variedad de técnicas que se han centrado tanto en el análisis de los datos, como el almacenamiento de estos y encuentran en la Big Data el lugar para relacionarse y combinarse. Un ejemplo de esto son los sistemas federados, los cuales están dirigidos a la integración de diferentes fuentes de información, buscando principalmente la interoperabilidad. Lo mismo sucede con las técnicas de minería de datos, las cuales se han centrado en las formas de analizar y extraer información útil. Todos estos avances previos, obviamente no han dejado de existir, sino que convergen (con ciertas características diferentes) en el concepto de Big Data y a su vez son extendidos para funcionar en entornos de grandes volúmenes de datos y grandes exigencias de procesamiento.

Tres grandes áreas de trabajo se pueden diferenciar en Big Data: almacenamiento, procesamiento y analítica de datos. La analítica de datos (data analytics) es un término abarcativo que se encarga de gestionar los datos en todo su ciclo de vida. Como es sabido, los datos sin procesar (raw data) por sí mismos no tienen un significado útil, por lo que la analítica de datos se dedica al proceso de extraer y crear información desde estos datos por medio de la recolección, limpieza, organización, almacenamiento, procesamiento, contextualización, análisis y gobernanza de datos. Existen 4 tipos de categorías para la analítica de datos que dependen de los resultados que producen: descriptiva, diagnóstica, predictiva y prescriptiva. En la siguiente figura podemos ver el significado de cada una de ellas y su principal intención, tanto en objetivo como complejidad y valores obtenidos.



Fuente: Arshdeep Bahga and Vijay Madisetti. Big Data


Science & Analytics: A Hands-On Approach. 1st Edición.

Actividad 2: Pensar un ejemplo de cada categoría de analítica de datos.

Las características principales de Big Data son:

1. Volumen: El volumen de información es inmenso. El mismo puede ser generado a partir de redes sociales, sistemas bancarios, sensores, internet de las cosas (IoT), etc.
2. Velocidad: Se refiere a la rapidez en que los datos se acumulan o generan. Es la base del crecimiento exponencial de los datos.
3. Variedad: Los datos pueden ser estructurados, semi-estructurados, y sin estructura; en formato de texto, imagen, video, audio, etc.
4. Veracidad: se refiere a la calidad o fiabilidad de los datos. Incluye conceptos sobre calidad de datos y sus impactos positivos y negativos.
5. Valor: se refiere a la utilidad del dato para el propósito que va a ser utilizado. Esta característica está relacionada con la veracidad ya que cuanto más confiable sea el dato, más útil debería ser. También se lo puede relacionar con el tiempo, ya que en algunos dominios, el tiempo en que el dato es útil para ser procesado es importante para las decisiones que se deben tomar.
6. Variabilidad: se refiere a que las fuentes de datos pueden cambiar. Por esto, se requieren mecanismos de adaptación para la evolución de los esquemas y a su vez de los datos, cuando nuevos datos deben ser ingresados.

Te invito a ver el siguiente video “¿Qué es el Big Data? - La mejor explicación en español”



para repasar los conceptos vistos.

Ahora que ya entendemos un poco mejor el concepto de grandes volúmenes de datos vamos a estudiar la diferencia con otros conceptos que suelen estar relacionados a la Ciencia de datos pero que no son exactamente lo mismo.

Big data vs Ciencia de datos

El procesamiento de grandes datos no se puede lograr fácilmente empleando métodos de análisis tradicionales.

Por lo tanto, se requieren técnicas, herramientas y sistemas de modelado de datos especializados para extraer información que sea valiosa para las organizaciones. Para conseguirlo surgió la ciencia de datos.

La ciencia de datos es un estudio detallado del flujo de información a partir de cantidades ingentes de datos presentes en el repositorio de una organización.

Se trata de obtener información significativa a partir de datos sin procesar y no estructurados que se analizan a través de habilidades analíticas, de programación y de negocios.

Para ello hace falta reunir muchas de las habilidades que impulsan a las compañías.

A continuación, se presentan algunas de las principales diferencias de la Ciencia de datos y el Big data:

- Los macrodatos (Big Data) se distinguen por su variedad, velocidad y volumen. Mientras que la ciencia de datos proporciona los métodos o técnicas para analizarlos.
- La inteligencia de datos proporciona el potencial de rendimiento. No obstante, es la ciencia de datos la que utiliza enfoques teóricos y experimentales, además del razonamiento deductivo e inductivo.
- El análisis de big data realiza la extracción de información útil de grandes volúmenes de conjuntos de datos. Contrariamente al análisis, la ciencia de datos utiliza algoritmos de aprendizaje automático y métodos estadísticos para entrenar a los ordenadores y obtener predicciones precisas. De este modo, la ciencia de los datos no debe confundirse con el análisis de los macrodatos.
- Big Data se relaciona más con la tecnología (Hadoop, Java, Hive, etc.) la computación distribuida y las herramientas y el software de análisis. Esto se opone al otro concepto que se enfoca en estrategias para decisiones de negocios, disseminación de datos utilizando matemáticas, estadísticas, etc.

¿Hace falta el big data para aplicar ciencia de datos en una organización?

De las diferencias anteriores se puede observar que el concepto de ciencia de datos se engloba dentro del concepto de big data. En este sentido, la ciencia de datos juega un papel importante en muchas áreas de aplicación.

En resumidas cuentas, la ciencia de datos se desenvuelve dentro del ámbito del big data para obtener información útil a través del análisis predictivo, donde los resultados se utilizan para tomar decisiones inteligentes. De esta forma, sin big data no existiría el concepto de data science. Y sin el segundo, el primero no tendría (u obtendría) tanto valor.

Big data vs Minería de datos

Como ya establecimos, el Big Data hace referencia al almacenamiento de grandes cantidades de datos y a los procedimientos usados para encontrar patrones repetitivos dentro de esos datos. Es la tecnología capaz de capturar, gestionar y procesar en un tiempo considerable y de forma eficiente estos datos.

Por su parte, la minería de datos es el proceso de identificación de toda la información que es relevante y es extraída de grandes cantidades de datos. El objetivo de esta extracción es descubrir patrones y tendencias estructurando la información que se ha obtenido de una manera que sea comprensible para su utilización.

La minería de datos reúne las ventajas de varias áreas como la Inteligencia Artificial, la Estadística, las Bases de Datos, la Computación Gráfica y el Procesamiento Masivo, especialmente usando como materia prima las bases de datos.



Fuente: <https://www.campusbigdata.com/>

Actividad 3: Explicar la figura propuesta. ¿ En qué se diferencia un telescopio de un microscopio? ¿Qué analogía podemos plantear de estos aparatos en el big data?

Aunque, el Big Data y la minería de datos están muy relacionadas con el uso de grandes cantidades de datos, cada una se utiliza para fines diferentes. La tecnología de minería de datos se presenta como una tecnología de apoyo, ya que nuestra capacidad para almacenar datos ha crecido en los últimos años a velocidades imparables pero la capacidad para procesar y utilizar esos datos no ha ido a la par.


Big data vs Aprendizaje de máquina

El machine learning (ML) o aprendizaje automático es una técnica dentro del área de la inteligencia artificial (IA) que busca dotar a las computadoras con la capacidad de “aprender”, tal y como lo hace una persona.

En este sentido, un algoritmo de machine learning desarrolla la capacidad de modificarse a sí mismo con el fin de adaptarse a los datos que está procesando. El objetivo de ello es poder resolver un problema computacional por su propia cuenta.

Dicho “problema” puede consistir en encontrar patrones ocultos de comportamiento o en ejecutar tareas complejas de forma automática. Así, un sistema con big data y machine learning puede captar problemas con los datos y al mismo tiempo resolverlos.

Te invito a ver el siguiente video “¿Cuál es la diferencia entre Big data, Inteligencia artificial, machine learning y deep learning?”



el cual plantea ejemplos de ambos conceptos.


La gestión de una organización se fundamenta en tomar decisiones adecuadas respecto a clientes, productos, empleados, proveedores y procesos de negocio. Por lo tanto, es necesario tener mecanismos que den soporte a una toma de decisiones eficiente.

Se entiende por business intelligence el conjunto de metodologías, aplicaciones, prácticas y capacidades enfocadas a la creación y administración de información que permite tomar mejores decisiones a los usuarios de una organización.

En esencia, mediante la inteligencia de negocio, podemos romper con la siguiente máxima: «Lo que no se define no se puede medir. Lo que no se mide, no se puede mejorar. Lo que no se mejora, se degrada siempre». William Thomson

En los últimos años, ha emergido una nueva forma de competir que se fundamenta en tomar decisiones basadas en datos y evidencias dejando atrás la intuición. Esta forma de competir combina diferentes estrategias para generar valor de negocio: business intelligence (BI), business analytics y big data. Podemos decir entonces que el Big Data es una de las estrategias que puede adoptar una organización para dar soporte a la toma de decisiones. Otra estrategia mencionada es business analytics que representa al conjunto de estrategias, tecnologías y sistemas que permiten analizar el rendimiento pasado de una organización para poder predecir comportamientos futuros, así como para detectar patrones ocultos en la información.

Ahora que conocemos las 3 estrategias podemos estudiar cómo se relacionan entre ellas a partir de la siguiente figura:



Fuente: Josep Curto

La lectura de este gráfico se realiza a partir de sus ejes. Por ejemplo, cuando necesitemos desarrollar capacidades analíticas descriptivas y la complejidad de dato sea alta combinaremos big data con business intelligence formando un único sistema.

Algunas de las tecnologías que forman parte de la business intelligence son estas:

- Data warehouse.
- Reporting.
- Análisis OLAP (online analytical processing).
- Análisis visual.
- Análisis predictivo.
- Cuadro de mando.
- Cuadro de mando integral.
- Minería de datos.
- Gestión del rendimiento.
- Previsiones.
- Reglas de negocio.
- Dashboards.
- Integración de datos (que incluye extract, transform and load; ETL).

Beneficios de un sistema de business intelligence

La implementación de estos sistemas de información proporciona diversos beneficios, entre los que podemos destacar:

- Crear un círculo virtuoso de la información: los datos se transforman en información que genera un conocimiento que permite tomar mejores decisiones que se traducen en mejores resultados y que generan nuevos datos.
- Proporcionar una visión única, conformada, histórica, persistente y de calidad de toda la información relevante para la organización.
- Crear, manejar y mantener métricas, indicadores claves de rendimiento (key performance indicator; KPI) e indicadores claves de metas (key goal indicator; KGI) fundamentales para la empresa.
- Habilitar el acceso a información actualizada tanto a nivel agregado como en detalle.
- Reducir el diferencial de orientación de negocio entre el departamento TI y la organización.
- Mejor comprensión y documentación de los sistemas de información en el contexto de una organización.
- Mejor comprensión de las opiniones y necesidades de los potenciales clientes a partir del análisis de redes sociales.
- Mejora de la competitividad de la organización como resultado de ser capaces de:
- Diferenciar lo relevante de lo superfluo.
- Acceder más rápido a la información.
- Tener mayor agilidad en la toma de las decisiones.

3. Instancia de Evaluación:

Participación en Foro obligatorio

Criterios de evaluación:

- Entregar en tiempo y forma
- Realizar un 60% de la actividad correctamente.
- Cumplir con las consignas
- Cumplir con el formato requerido.

En esta instancia de evaluación deberás participar en el foro subiendo las actividades propuestas en la clase y cualquier otra apreciación de los contenidos vistos que te parezca relevante.

Recuerda leer la colaboración de tus compañeros y evita dar respuestas que ya han sido elaboradas por ellos. Si es posible intervení en las respuestas de tus compañeros.

4. Actividad Integradora de Cierre:

A partir de todo lo visto en esta clase te invito a investigar sobre las organizaciones que hoy en día aplican alguna de las estrategias estudiadas, qué tecnologías las soportan, casos de éxito y de fracasos si los hubiera. ¿Qué factores consideras que influyen a la hora de evaluar la factibilidad de aplicación de estas estrategias? (costos, recursos humanos disponibles, acceso a la tecnología, etc.). Todo lo que consideres interesante deberás compartirlo en el foro de esta clase.

5. Cierre/Reflexión Final:

Como cierre de esta primera clase te invito a que reflexiones sobre las siguientes preguntas ¿Qué aprendimos sobre el procesamiento de grandes volúmenes de datos? ¿Para qué sirve? ¿Por qué es importante?

En la próxima clase estaremos estudiando las etapas del desarrollo de programas de procesamiento de datos y las distintas tareas que se ejecutan en cada una de ellas.

Te esperamos en los próximos encuentros. Recordá que es importante participar de los foros, de los encuentros sincrónicos y en lo posible de las tutorías presenciales.

Te invitamos a que nos dejes tus impresiones sobre lo que aprendimos hoy en el foro de intercambio. También podés compartir links de artículos o videos que te hayan parecido interesantes mientras estudiabas este tema.

6. Bibliografía Obligatoria:

Jones, H. (2019). Ciencia de Los Datos: La Guía Definitiva Sobre Análisis de Datos, Minería de Datos, Almacenamiento de Datos, Visualización de Datos, Big Data Para Empresas Y Aprendizaje Automático Para Principiantes.

<https://cepei.org/> Centro de Pensamiento Independiente

Miller, D. (2007). Measuring Business Intelligence Success: A Capability Maturity Model. Nueva York: D. M. Morrisey.