

PROCESAMIENTO DE DATOS

2º 1º Cuatrimestre



2. Clase 2

Clase N° 2: Etapas del desarrollo de programas de procesamiento de datos

Contenido:

En la clase de hoy trabajaremos los siguientes temas:

- Ciclo completo del procesamiento de datos
- Introducción de cada etapa y las actividades que involucran

1. Presentación

Hola y bienvenidos al curso de Procesamiento de datos.

En esta segunda semana vamos a estudiar las etapas del desarrollo de programas de procesamiento de datos. Veremos el ciclo completo del procesamiento de datos desde su recolección hasta la presentación de los resultados. Si bien veremos de forma introductoria cada etapa y las actividades que involucran, en las próximas semanas retomaremos sobre algunas de ellas y las veremos con mayor profundidad tanto de forma teórica como práctica. En la clase pasada, estudiamos la conceptualización de Big Data y sus diferencias con la Ciencia de Datos. Hoy veremos las etapas del procesamiento de datos y cómo se aplican en distintos escenarios.

Para empezar te invito a analizar la siguiente imagen y pensar cómo los distintos conceptos que aparecen se relacionan con el BIG DATA




Fuete: Linkdin

2. Desarrollo y actividades

Ciclo de vida en el procesamiento de datos

El ciclo de vida de Big Data o de procesamiento de datos es diferente al ciclo de vida de un desarrollo de software tradicional.

Aunque no hay un consenso general de las etapas exactas que debe tener este proceso, podemos diferenciar 6 actividades a ser realizadas según la siguiente figura:



Fuente: Thomas Erl

Actividad 1: La etapa de preparación de datos plantea 4 tareas a realizar ¿solo se realizan una sola vez en todo el ciclo? ¿Es posible que alguna de ellas se realicen en paralelo? ¿cuándo sí o cuándo no? ¿Cuáles crees que son las etapas más críticas en la toma de decisiones?

Las mismas son:

1. Evaluación del Caso del Negocio: se debe comenzar un proceso de Big Data con un caso de negocio bien definido que denote un claro entendimiento de la justificación, motivación y metas de llevar a cabo el análisis. De esta manera, se pueden proyectar los recursos (físicos, humanos, tecnológicos) a ser utilizados y estimar los costos de llevarlo a cabo.

2. Identificación y recolección de datos: se deben identificar los datos requeridos para analizar y las fuentes confiables de donde obtenerlos. A su vez se debe definir la forma en la que se realizará la recolección de estos. Dependiendo del alcance del análisis, los datos pueden ser internos o externos a la empresa.


3. Preparación de datos: involucra muchas actividades en donde la limpieza, normalización, reestructuración y filtrado son tareas principales. A su vez, se deben definir mecanismos para la forma de extraer estos datos, y la forma y lugar donde almacenarlos. A su vez, puede necesitar realizar tareas de integración de datos buscando similitudes entre atributos de diferentes fuentes que sean similares. Por último, se debe seleccionar un repositorio en donde almacenar toda la información procesada.

4. Análisis de datos: puede clasificarse en confirmatorio o exploratorio. El análisis confirmatorio es un enfoque deductivo en donde se propone una hipótesis y se comprueba o no la veracidad de la misma. En general en este tipo de análisis no se encuentran anomalías o resultados no esperables ya que se preparan los datos para la hipótesis que se desea comprobar. Luego, el análisis exploratorio es un enfoque inductivo donde no hay hipótesis planteadas y los datos son explorados para entender por ejemplo la causa de un determinado fenómeno. A pesar de que este análisis no provee respuestas definitivas, es útil para descubrir patrones o anomalías.

5. Modos de Análisis: una vez que se define el tipo de análisis a realizar se debe determinar el modo de procesarlo, el cual puede ser: por lotes (batch), tiempo real, o interactivo. La elección de este modo va a depender de los requerimientos de la aplicación. Si la aplicación demanda resultados actualizados entre intervalos cortos de tiempo (pocos segundos), entonces el modo debe ser en tiempo real. En cambio, si estos intervalos de tiempo son muy largos (días o meses), puede usarse el modo batch. Por último, el modo interactivo se utiliza cuando se requiere flexibilidad en cuanto a la consulta de los datos bajo demanda. Una vez seleccionado el modo, se pueden elegir las herramientas disponibles para llevarlo a cabo.

6. Visualización y utilización de los resultados: muchas veces los resultados de los análisis anteriores son muy difíciles de comprender en los formatos en los que salen, por lo que se recurren a técnicas de visualización que permiten comunicar los resultados en forma amigable a los analistas y usuarios comunes. Estas técnicas de visualización se dividen en estáticas, dinámicas e interactivas. Son estáticas cuando se basan en valores obtenidos de un repositorio y simplemente muestran resultados, dinámicas cuando los resultados se actualizan regularmente, e interactivas cuando se consideran las entradas de los usuarios. Al mismo tiempo, muchas veces es necesario determinar qué acciones realizar con los datos del análisis obtenido, las cuales podrían ser realimentar sistemas existentes, realizar alertas, re-implementaciones, cambiar procesos de la empresa, etc. Finalmente, los resultados de los análisis deben ser también almacenados en algún tipo de formato y/o repositorio.

En la siguiente figura se resumen algunas de las técnicas relacionadas con cada etapa descripta.



Fuente: UNPA – Dirección de Informática

En la figura propuesta encontrarás varias técnicas que quizás no conozcas aún. La idea de la clase de esta semana es mencionarlas y ubicarlas en cada etapa del ciclo de procesamiento de datos, en las próximas semanas estaremos estudiando algunas de estas técnicas tanto en la teoría como en la práctica. También notarás que existen algunos conceptos que habrás estudiado en otros cursos como estadísticas y SQL.


Ejemplo de Aplicación

Un ejemplo de aplicación puede ser para el análisis de datos del clima. Veremos para cada una de las actividades junto el conjunto de técnicas y herramientas seleccionadas.

Estas son:

1. Evaluación del Caso del Negocio: existen dos objetivos para realizar el análisis: (1) la agregación y consulta de datos para obtener información básica de la información que se recupera de los sensores climáticos, y (2) realizar predicciones acerca de valores y/o eventos climáticos posibles.

2. Identificación y recolección de datos: La entrada para el análisis proviene de un conjunto de estaciones de monitoreo que poseen sensores de temperatura, humedad, viento y presión. Para recolectar los datos de los sensores se utiliza un framework de mensajería del tipo publicador/suscriptor para realizar un análisis en tiempo real, y un conector source sink para poblar datos a un sistema de archivos distribuido (HDFS). Te invito a ver el siguiente breve video "BigData: Hadoop Distributed File System (HDFS)" que explica de forma clara y sencilla cómo funciona HDFS



3. Preparación de datos: como los datos del clima se obtienen desde diferentes estaciones de monitoreo, se deben preparar los datos previo a alimentar los repositorios. Los datos pueden venir en diferente formato, con diferentes medidas, duplicados, etc. Todo esto hay que pre-procesarlo para que los datos ingresen lo más limpios y normalizados posible. Luego, estos datos limpios se ingresan a un sistema de archivos distribuido (HDFS) - donde se realizará luego un análisis batch.

4. Análisis de datos: dado los objetivos planteados en la primera actividad se seleccionan diferentes tipos de análisis. El primer objetivo, agregación y consulta de datos, se enmarca en las técnicas de análisis de estadísticas básicas y se puede realizar con SparkSQL. Con esto se podrá realizar una agregación de datos en diferentes escalas de tiempo (en minutos, en horas, diaria o mensualmente) para determinar las lecturas medias, máximas, y mínimas para la temperatura, humedad, viento y presión, y encontrar información acerca de, por ejemplo, los días con temperaturas más bajas en un mes determinado, los diez días más húmedos del año, etc. Luego, para el segundo objetivo, realizar predicciones, se pueden utilizar técnicas de clasificación usando KNN o árboles de decisión, para predicciones de ciertos eventos climáticos, como predecir lluvias, niebla, etc.; y modelos de regresión con SparkMLlib para realizar predicciones de valores, como la cantidad de lluvia que caerá.

5. Modos de Análisis: basado en las actividades anteriores, los modos de análisis son de los 3 tipos conocidos.

6. Visualización y utilización de los resultados: el front-end de la aplicación para visualizar el análisis es dinámico e interactivo y los resultados se almacenarán en la BD NoSQL Dynamo. También se utiliza Django para desarrollar las aplicaciones web para la muestra de los datos.

Prestar atención que en este ejemplo se usa una Base de Datos NOSQL... pero ¿qué es una base de datos NOSQL? Son bases de datos no relacionales que almacenan datos en un formato distinto a las tablas relacionales y no usan el lenguaje SQL para las consultas. Algunos ejemplos de tipos de estas bases de datos son: clave-valor, gráficos, documentos.

Te invito a visitar la web de AMAZON donde se explica en mayor detalle este tipo de bases de datos y cómo se diferencian con las demás existentes <https://aws.amazon.com/es/nosql/>

Actividad 2: Comparar las ventajas y desventajas de las Bases SQL y NOSQL.

Actividad 3: Pensar ejemplos de cada tipo de base de datos.

Instancia de Autoevaluación: Registro de Intercambio -FORO OBLIGATORIO

Criterios de evaluación:

- Entregar en tiempo y forma
- Realizar un 60% de la actividad correctamente.
- Cumplir con las consignas
- Cumplir con el formato requerido.

En esta instancia de autoevaluación deberás participar en el foro subiendo las actividades propuestas en la clase y cualquier otra apreciación de los contenidos vistos que te parezca relevante.

Recuerda leer la colaboración de tus compañeros y evita dar respuestas que ya han sido elaboradas por ellos. Si es posible interviní en las respuestas de tus compañeros.

3. Actividad Integradora de Cierre:

A partir de todo lo visto en esta clase te invito a investigar sobre las organizaciones que hoy en día aplican alguna de las estrategias estudiadas, qué tecnologías las soportan, casos de éxito y de fracasos si los hubiera. ¿Qué factores consideras que influyen a la hora de evaluar la factibilidad de aplicación de estas estrategias? (costos, recursos humanos disponibles, acceso a la tecnología, etc.) Además, en esta clase hemos introducido algunas técnicas de análisis como batch pero también mencionamos las técnicas en tiempo real e interactivas ¿en qué se diferencian?

4. Cierre:

Como cierre de esta primera clase te invito a que reflexiones sobre las siguientes preguntas, si bien el ciclo de vida para el procesamiento de grandes volúmenes de datos define una serie de actividades que deben seguirse ¿Cuántas técnicas y herramientas existen para llevar a cabo cada una de esas actividades? ¿Siempre es mejor una técnica que otra? ¿Cómo podemos elegir cuál es la más adecuada según el trabajo a realizar?

En la próxima clase estaremos estudiando las herramientas de software y lenguajes de programación para Ciencia de Datos.

Te esperamos en los próximos encuentros. Recordá que es importante participar de los foros, de los encuentros sincrónicos y en lo posible de las tutorías presenciales.

5. Bibliografía Obligatoria:

Jones, H. (2019). Ciencia de Los Datos: La Guía Definitiva Sobre Análisis de Datos, Minería de Datos, Almacenamiento de Datos, Visualización de Datos, Big Data Para Empresas Y Aprendizaje Automático Para Principiantes.

<https://cepei.org/> Centro de Pensamiento Independiente

Miller, D. (2007). Measuring Business Intelligence Success: A Capability Maturity Model. Nueva York: D. M. Morrisey.