



PROCESAMIENTO DE DATOS

2º 1º Cuatrimestre



3. Clase 3

Clase N° 3: Herramientas de software para datawarehouse

Contenido:

En la clase de hoy trabajaremos los siguientes temas:

- Introducción a los Data Warehouse
- Arquitectura de los Data Warehouse
- Software pagos y open source

1. Presentación

Hola y bienvenidos al curso de Procesamiento de datos.

En esta cuarta semana de clases estudiaremos el concepto de DATWAREHOUSE y compararemos distintos software para su implementación tanto pagos como de licencia libre, cada una con sus ventajas y desventajas.

2. Desarrollo y actividades

En el contexto de la Business Intelligence, hoy la base de estos sistemas de información la proporciona generalmente un depósito central de datos que se conoce como Data Warehouse (DWH, en español almacén de datos). A continuación, explicamos qué es un almacén de datos y cuál es su estructura y presentamos diferentes soluciones de software para instalar y gestionar un data warehouse tanto de proveedores comerciales como de código abierto.

¿Qué es un data warehouse?

Un almacén de datos es un sistema de base de datos separado de los sistemas operativos de procesamiento de datos (bases de datos transaccionales), en el cual se comprimen y guardan a largo plazo datos procedentes de fuentes diferentes y en ocasiones muy heterogéneas. Muchas empresas vuelcan periódicamente los datos históricos que guardan estas bases de datos transaccionales en un almacén de datos, y los preparan y limpian para poder acceder a ellos más tarde y analizarlos estratégicamente en el marco de la inteligencia empresarial. En este proceso, los datos operativos (transaccionales) se convierten en datos preparados y útiles:

Datos operativos: se trata de información transaccional que generan los sistemas de administración y cuentas en la práctica comercial cotidiana. Entre las fuentes típicas de datos transaccionales se cuentan sistemas de administración de datos como los programas de contabilidad, los sistemas de gestión de mercancías, los sistemas de planificación de recursos de empresa (ERP) o los sistemas de ayuda y pedido.

Datos útiles: son los datos que resultan cuando los datos operativos de uso cotidiano se agrupan, guardan, depuran y preparan para el análisis en un lugar central separado.

Un DWH les ofrece a los analistas un amplio campo de visión sobre datos de origen muy heterogéneos y permite agregar indicadores operativos en el contexto del procesamiento analítico en línea (Online Analytical Processings, OLAP). Como depósito central de todos los datos empresariales relevantes, a los que suele accederse exclusivamente con permiso de lectura, el almacén de datos contribuye a la gestión del conocimiento interno del negocio. Como base sobre la cual trabajan los diversos métodos de minería de datos, el contenido de un DWH sostiene todas las reflexiones y tomas de decisiones en relación con la gestión del rendimiento y la planificación estratégica del negocio.

¿Cómo se estructura un data warehouse?

Al proceso de gestión y examen de un almacén de datos se le denomina data warehousing y este comprende las siguientes fases:


- Obtención e integración de los datos
- Conservación de los datos
- Evaluación y análisis de los datos

Estas tres fases se reflejan en una arquitectura ideal básica, un modelo de referencia de los sistemas de almacén de datos que, si bien puede constatar diferencias en función del producto y el fabricante, en principio se orienta por una estructura modular a tres niveles:

- Recolección
- Almacenamiento y conservación
- Entrega (para su consulta)

A estos tres niveles se añade un componente central de control, el gestor del almacén de datos (Data Warehouse Manager), que asigna a cada nivel funciones especiales de administración.

Los diversos componentes que integran un almacén de datos no tienen que proceder del mismo fabricante, sino que pueden tener origen en productos de software diferentes o en soluciones individuales. El siguiente gráfico ilustra esquemáticamente la arquitectura de referencia de un data warehouse:



Nivel de obtención de los datos

Antes de cargar los datos en el almacén, esta información, a menudo muy diversa, se ha de convertir a un formato homogéneo. Un almacén de datos se nutre tanto de fuentes internas de la empresa como de fuentes externas especialmente relevantes:

Datos internos de sistemas de planificación de recursos de empresa (Enterprise Resource Planning, ERP), de sistemas gestión de las relaciones con los clientes (Customer Relationship Management, CRM), de bases de datos transaccionales, de gestores de contenido (CMS), de archivos (Excel, CSV, texto), de correos electrónicos, etc.

Datos externos desde aplicaciones y sistemas de terceros, páginas web o Internet, redes sociales, servicios en la nube, etc.

Los sistemas que actúan en este nivel se comunican con los sistemas operacionales de una empresa por medio de interfaces que se utilizan en la primera fase del almacenamiento del data warehousing. Las funciones centrales de estos sistemas son la recolección y la integración de los datos.

Los datos se obtienen utilizando los siguientes métodos de extracción:

Trigger (disparador): si los sistemas operacionales de una empresa soportan disparadores de bases de datos, estos se pueden utilizar para automatizar la extracción de datos. Los disparadores permiten definir operaciones que se ejecutan tan pronto se producen determinados eventos, que suelen consistir en cambios en la base de datos del sistema de origen. Esto conduce a la extracción de los datos modificados hacia el almacén de datos.

Archivos de protocolo: si un sistema operacional no soporta la tecnología de disparadores, el nivel de recolección de datos puede contener programas capaces de examinar los archivos de protocolo o logs del sistema de origen y extraer las operaciones que se han registrado.

Programas de monitorización: si no se cuenta con disparador ni con archivos de protocolo, suelen utilizarse programas de supervisión que extraen los cambios en los datos de un sistema operacional a partir de algoritmos que generan snapshots de los datos periódicamente y los comparan con los anteriores.

Cuando, al no ser posible acceder a las bases de datos, los sistemas no soportan ninguno de estos tres métodos, han de ser ellos mismos los que protocolicen los posibles cambios y envíen cualquier modificación relevante al data warehouse.

En cuanto a la integración de los datos, la mayor parte de almacenes de datos contienen funciones de procesamiento analítico en línea (OLAP) que permiten trasladar los datos a estructuras multidimensionales. El denominado Online Analytical Processing es un método analítico basado en el proceso ETL con el que se comprimen los datos de gestión relevantes para la empresa:

Al proceder de fuentes diferentes, la integración de estos datos en el almacén recurre a diversas herramientas de transformación y limpieza que pueden clasificarse según estas tres categorías.

- Herramientas de migración de datos: estos programas permiten definir reglas simples de transformación que conviertan los datos de salida heterogéneos en un formato de destino uniforme.
- Herramientas de limpieza: en este caso, estos programas se apoyan en la llamada lógica difusa (fuzzy logic) y en las redes neuronales para mejorar la calidad de los datos en tanto que corrige errores, datos incompletos y repeticiones. Para llevar a cabo esta depuración de registros, utiliza reglas predefinidas, algoritmos o tablas de consulta (lookup tables). Esta operación también suele denominarse gestión de la calidad (quality management).
- Herramientas de auditoría de datos: estos programas se utilizan para encontrar reglas y relaciones entre los datos, así como también para identificar aquellos que contravienen las reglas definidas y son previsiblemente erróneos.

Nivel de conservación de los datos

Este nivel constituye el núcleo del almacén de datos y comprende el denominado Core Data Warehouse o almacén maestro. Los datos extraídos en la fase anterior se guardan en él en la forma de matrices multidimensionales (esquemas de bola de nieve y de estrella) y se mantienen aquí con vistas a ser archivados a largo plazo para análisis futuros. Dado que estos análisis rara vez tienen como objeto el contenido completo del almacén de datos, para garantizar un examen eficiente suele ser habitual crear los denominados data marts (mercados de datos), basados en subconjuntos o extractos de la información total contenida en el almacén central.

Un data mart es una copia de un subconjunto de datos generalmente realizada como copia temporal no persistente. En ocasiones también se utilizan los llamados data marts independientes, que guardan un subconjunto de datos separado de forma perdurable.

Nivel de entrega de los datos

Este nivel funciona como interfaz para las aplicaciones finales y las herramientas de presentación, que facilitan métodos de análisis y evaluación de datos que permiten extraer la información de los almacenes de datos y prepararlos de distintas formas para el usuario final. Entre estas se incluyen herramientas de elaboración de informes y de consultas, de colaboración, de minería de datos, de OLAP, sistemas de información ejecutiva (EIS) y herramientas de proyección y simulación.

Herramientas de consulta e informes

Este tipo de programas ponen a disposición del usuario diferentes funciones para elaborar informes estándar (predefined reportings) de forma automatizada cada cierto tiempo o bajo petición. Los programas de consulta simplifican la realización de consultas al almacén de datos predefiniéndolas.

Herramientas de colaboración

Los programas de colaboración apoyan la comunicación y el trabajo conjunto de los usuarios en el análisis de los datos. La gama de funciones de estas herramientas comprende, por ejemplo, el almacenamiento de comentarios y el intercambio de resultados de análisis.

Herramientas de minería de datos

Bajo el título de data mining o minería de datos se engloban todos aquellos métodos de análisis no direccionales, en parte automatizados, que tienen como objetivo encontrar patrones, tendencias y relaciones relevantes en la información. Los programas de minería de datos se apoyan en métodos estadísticos y matemáticos, así como en tecnologías de inteligencia artificial (KI) y de aprendizaje automático. El volumen de los datos que las empresas generan, procesan y agrupan en almacenes de datos para analizarlos crece de forma exponencial y cada dos años se duplica el volumen medio de datos en todo el mundo. En este contexto, los métodos de minería de datos aplicados al data warehousing no hacen más que ganar en relevancia.

Herramientas de Online Analytical Processing (OLAP)

Entre las herramientas disponibles de análisis y evaluación en almacenes de datos se han consolidado las aplicaciones de OLAP como interfaz estándar de usuario. Las herramientas que se utilizan en el marco del procesamiento analítico en línea presentan funciones con las cuales los usuarios pueden formular consultas específicas (ad hoc) al almacén de datos que permiten explorar el contenido multidimensional del mismo.


Te invito a ver los siguientes dos videos "Soluciones Informáticas para la empresa - DataWareHouse (I) - Belén López"

poli [Media] UCAM | UNIVERSIDAD CATÓLICA DE MURCIA

Definición (I)

Sistema de almacenamiento de la información orientado a la decisión, que permite un acceso ágil a la información clave de una empresa, así como gran flexibilidad a la hora de definir consultas, resúmenes, diagramas o informes.





ambos de la

UCAM Universidad Católica de Murcia para complementar la lectura.

Software para data warehouses

El archivado en almacenes de datos ya no es un lujo exclusivo de las grandes corporaciones, pues las pequeñas y medianas empresas empiezan a descubrir el potencial derivado de la optimización de los procesos mediante el análisis de grandes volúmenes de datos. Al lado de suites profesionales de Business Intelligence y soluciones completas de DWH han ido surgiendo en los últimos años productos más asequibles con los que iniciarse, servicios en la nube más flexibles y aplicaciones de código abierto más ajustadas a las necesidades de la pyme.

Programas de data warehousing de pago

El software comercial de BI con cierto renombre suele distinguirse por una elevada fiabilidad, una gama de funciones acorde con los Service Level Agreements (SLA) y una atención al cliente de gran calidad, pero también por el coste de su adquisición o de su utilización como servicio en la nube.

La siguiente lista enumera los productos de pago disponibles en la actualidad de fabricantes de primera línea en orden alfabético:

Proveedores de software propietario	Productos de data warehousing
Amazon Web Services	Amazon Redshift
Cloudera	Cloudera Enterprise
Hewlett Packard Enterprise	HP Vertica
	HP ArcSight Data-Platform
	HP Haven OnDemand
	HP IDOL
	HP Key View
IBM	IBM Netezza
	IBM PureData System
	IBM InfoSphere DataStage
Microsoft	SQL Server
	Microsoft Analytics Platform System

Soluciones open source de data warehousing

Además de las soluciones propietarias de alto nivel, el mercado del software de inteligencia de negocio también ofrece soluciones de código abierto que facilitan funciones de data warehousing de forma gratuita. La siguiente comparativa se basa en información del Ministerio Alemán de Economía y Energía y muestra los programas más utilizados así como sus ámbitos de aplicación:

Proveedores de software propietario	Productos de data warehousing
	Azure HDInsight for Hadoop
Oracle	Oracle Business Intelligence
	Oracle Database
	Oracle Exadata Database Machine
	Oracle NoSQL Database
	Oracle TimesTen In-Memory Database
	Oracle Big Data Appliance
Pivotal Software	Pivotal Greenplum
	Pivotal Big Data Suite
	Pivotal HDB (powered by Apache HAWQ)
	Pivotal HDP (OEM Hortonworks Data Platform)
SAP	SAP NetWeaver Business Intelligence
	SAP IQ
	SAP HANA Enterprise Cloud
SAS	SAS Data Management
	SAS Access Interface to Hadoop
	SAS Federation Server
	SAS Data Loader for Hadoop
	SAS Event Stream Processing
Snowflake Computing	Snowflake
Teradata	Teradata Active Enterprise Data Warehouse
	Teradata Data Warehouse Appliance
	Teradata Appliance for Hadoop
	Teradata Integrated Big Data Platform
	Teradata Aster Big Analytics Appliance

Software BI	Extrae datos puros	Transforma datos puros	Carga datos transformados	OLAP	Data Mining	Panel de control	Informes
Pentaho DI	✓	✓	✓	-	-	-	-
Talend OS	✓	✓	✓	-	-	-	-
Jasper ETL	✓	✓	✓	-	-	-	-
Pentaho Mondrian	✓	-	-	✓	-	-	✓

Software BI	Extrae datos puros	Transforma datos puros	Carga datos transformados	OLAP	Data Mining	Panel de control	Informes
Jedox	✓	-	-	✓	-	✓	✓
BIRT	✓	-	-	-	-	✓	✓
SQL Power Wabit	✓	-	-	✓	-	✓	✓
KNIME	✓	✓	✓	✓	-	✓	✓
RapidMiner	✓	✓	✓	✓	✓	✓	✓
Weka	✓	✓	-		✓	-	✓
JasperSoft	✓	✓	✓	✓		✓	✓
Pentaho	✓	✓	✓	✓	✓	✓	✓
SpagoBI	✓	✓	✓	✓	✓	✓	✓

3. Instancia de Autoevaluación: Espacio de entrega de tarea

A partir de todo lo visto en esta clase te invito a investigar sobre las herramientas disponibles para la implementación de un data warehouse en las organizaciones. Elige al menos 2 herramientas de pago y 2 herramientas open source y realiza un pequeño informe de cada una. Compara sus ventajas y desventajas. ¿En qué tipos de proyectos o con qué tipos de fuentes de datos puede ser mejor una u otra?

Es importante tener en cuenta que para aprobar esta instancia deberás:

- Entregar en tiempo y forma
- Realizar un 60% de la actividad correctamente.
- Cumplir con las consignas
- Cumplir con el formato requerido.

4. Cierre:

Como cierre de esta primera clase te invito a que reflexiones sobre las preguntas planteadas en la actividad integradora. También te invito a buscar más herramientas para manejo de los data warehouse que no hemos presentado en esta clase y compartir información y opiniones en los encuentros sincrónicos.

Te esperamos en los próximos encuentros. Recordá que es importante participar de los foros, de los encuentros sincrónicos.

5. Bibliografía Obligatoria:

Davenport, T.; Harris, J. (2008). Competing on Analytics. Boston: Harvard Business School Press.

Franco, J. M.; EDS-Institut Prométhéus (1997). El Data Warehouse - El Data Mining. Barcelona: Gestión 2000.

Gill, H. S.; Rao, P. C. (1996). Data Warehousing. La integración para la mejor toma de decisiones. México: Prentice Hall.

Inmon, W. H.; Hackathorn, R. D. (1994). Using the data warehouse. Nueva York: Wiley.

Inmon, W. H.; Strauss, D.; Neushloss, G. (2010). DW 2.0: The Architecture for the Next Generation of Data Warehousing. Burlington, Mass.: Morgan Kaufman Series in Data Management Systems.

Kimball, R. (2002). The Data warehouse toolkit: the complete guide to dimensional modeling. Nueva York: Wiley

